

Project PBA
ANALISIS SENTIMEN ARTIKEL BERITA PADEL DI
INDONESIA MENGGUNAKAN FINE - TUNING MODEL BERT



Disusun oleh :

Daniel Bara Seftino	(5026231169)
Oryza Reynaleta Wibowo	(5026231081)
Metta Anjali Putri	(5026231205)
Muhammad Naufal Erwin Effendi	(5026231152)
Muhammad Abyansyah Putra Dewanto	(5026231052)

PENGOLAHAN BAHASA ALAMI (A)

DEPARTEMEN SISTEM INFORMASI

FAKULTAS TEKNOLOGI ELEKTRO DAN INFORMATIKA CERDAS

INSTITUT TEKNOLOGI SEPULUH NOPEMBER SURABAYA

TAHUN AJARAN 2026/2027

DAFTAR ISI

DAFTAR ISI.....	2
ABSTRAK.....	3
BAB I.....	4
PENDAHULUAN.....	4
1.1 Latar Belakang.....	4
1.2 Rumusan Masalah.....	5
1.3 Tujuan Penelitian.....	5
BAB II.....	6
TINJAUAN PUSTAKA.....	6
2.1 Analisis Sentimen pada Domain Olahraga.....	8
2.2 Analisis Sentimen pada Teks Berita Daring.....	8
2.3 IndoBERT dan Fine-Tuning Model Transformer untuk Bahasa Indonesia.....	9
2.4 Perkembangan Olahraga Padel dan Relevansinya sebagai Objek Kajian.....	10
BAB III.....	11
METODOLOGI.....	11
3.1 Metodologi Penelitian.....	11
3.2 Uraian Alur Pelaksanaan Penelitian.....	12
3.2.1 Akuisisi Data.....	12
3.2.2 Analisis Sentimen Dasar.....	13
3.2.3 Pre-pemrosesan Data.....	14
3.2.3.1 Uppercase-to-Lowercase.....	14
3.2.3.1 Tokenisasi.....	14
3.2.3.1 Penghapusan Stopwords.....	14
3.2.3.1 Lemmatization.....	15
3.2.3.1 Penyimpanan Hasil Pemrosesan.....	15
3.2.4 Pemilihan Model.....	15
3.2.5 Fine-Tuning Model.....	16
3.2.5.1 Exploratory Data Analysis (EDA).....	16
3.2.5.2 Pemuatan Model dan Tokenizer.....	16
3.2.5.3 Pengaturan Konteks.....	16
3.2.5.4 Prediksi Sentimen.....	16
3.2.5.5 Penerapan pada Dataset dan Penyimpanan Hasil.....	16
3.2.6.1 Analisis TF-IDF.....	17
3.2.6.2 POS Tagging.....	17
3.2.6.3 Named Entity Recognition (NER).....	17
3.2.6.4 Analisis N-gram.....	17

BAB IV.....	18
HASIL DAN PEMBAHASAN.....	18
4.1 Hasil Akuisisi Data.....	18
4.1.1 Hasil Akuisisi RSS Feed Google News.....	18
Gambar 4.1 Hasil Akuisisi RSS Feed Google News.....	18
4.1.2 Hasil Akuisisi RSS Direct Feed.....	18
Gambar 4.2 Hasil Akuisisi RSS Direct Feed (Web Scrapping).....	19
4.1.3 Hasil Akuisisi RSS Bing News Search.....	19
Gambar 4.3 Hasil Akuisisi RSS Bing News Search.....	19
4.1.4 Hasil Akuisisi Merge dan Deduplikasi.....	19
Gambar 4.4 Hasil Deduplikasi dan Distribusi Portal Berita.....	19
Gambar 4.5 Hasil Akuisisi RSS Bing News Search.....	20
Gambar 4.6 Hasil Artikel Padel yang Sudah di-cleaning.....	20
4.2 Hasil Pra-Pemrosesan Data.....	20
4.2.1 Hasil Normalisasi Uppercase-to-Lowercase.....	21
Gambar 4.7 Hasil Normalisasi Uppercase-to-Lowercase.....	21
4.2.2 Hasil Tokenisasi.....	21
Gambar 4.8 Hasil Tokenisasi.....	21
4.2.3 Hasil Stopwords Removal.....	21
Gambar 4.9 Daftar dan Kode Custom Stopwords.....	22
Gambar 4.9 Hasil Stopwords Removal.....	22
4.2.3 Hasil Lemmatization.....	22
Gambar 4.11 Hasil Lemmatization.....	22
4.3 Hasil Fine-Tuning dengan Menggunakan IndoBERT.....	22
Gambar 4.11 Hasil Exploratory Data Analysis (EDA) setelah Pre-Processing....	23
Gambar 4.12 Kode Pemodelan dengan IndoBERT.....	24
Gambar 4.13 Hasil Analisis Sentimen dengan IndoBERT.....	24
Gambar 4.14 Hasil Distribusi Sentimen per Portal Berita.....	25
Gambar 4.13 Hasil Performa Model IndoBERT.....	25
Gambar 4.14 Initial Code untuk Analisis TF-IDF.....	26
Gambar 4.15 show_top_words Function Code.....	27
Gambar 4.16 Hasil TF-IDF 15 Kata Paling Signifikan per Kelas Sentimen.....	27
Gambar 4.17 Kode dan Hasil Filtering Portal Berita.....	28
Gambar 4.17 Hasil Top 10 TF-IDF per Portal Berita.....	29
Gambar 4.18 Hasil Artikel Valid per Informasi Rilis Bulan-Tahun.....	29
Gambar 4.19 Top 10 TF-IDF per Bulan.....	30
Gambar 4.20 Top 10 TF-IDF per Keywords Pencarian.....	31
BAB V.....	34
PENUTUP.....	34
5.1 Kesimpulan.....	34
5.2 Saran.....	35

DAFTAR PUSTAKA	
LAMPIRAN.....	38

ABSTRAK

Olahraga padel tengah mengalami pertumbuhan pesat di Indonesia, khususnya di wilayah perkotaan, yang memicu peningkatan volume pemberitaan di media daring. Penelitian ini bertujuan untuk menganalisis sentimen publik terhadap perkembangan olahraga padel di Indonesia melalui artikel berita dengan menggunakan model *Deep Learning* berbasis IndoBERT. Data dikumpulkan dari berbagai portal berita daring nasional melalui metode *web scraping*, menghasilkan korpus final sebanyak 789 artikel setelah melalui proses pembersihan dan validasi.

Metodologi penelitian mencakup tahap pra-pemrosesan teks, *fine-tuning* model IndoBERT-base-p2, serta ekstraksi fitur menggunakan TF-IDF, POS Tagging, dan *Named Entity Recognition* (NER). Hasil penelitian menunjukkan bahwa model IndoBERT mencapai akurasi keseluruhan sebesar 87%, meskipun performa pada kelas minoritas (positif dan negatif) masih terbatas akibat ketidakseimbangan data yang ekstrem. Analisis distribusi sentimen mengungkap bahwa mayoritas pemberitaan bersifat netral (95,7%), yang mengindikasikan dominasi konten informatif dan faktual. Analisis tematik melalui TF-IDF berhasil mengidentifikasi pola isu yang berbeda, mulai dari aspek teknis lapangan hingga isu sosial terkait pembangunan fasilitas. Penelitian ini memberikan kontribusi pada pemahaman dinamika opini publik terhadap tren olahraga baru di Indonesia berbasis data tekstual formal.

Kata Kunci: Analisis Sentimen, IndoBERT, Olahraga Padel.

BAB I

PENDAHULUAN

1.1 Latar Belakang

Dalam beberapa tahun terakhir, olahraga padel mengalami perkembangan yang signifikan di Indonesia dan mulai menjadi bagian dari tren gaya hidup masyarakat urban. Padel merupakan olahraga raket yang mengombinasikan elemen tenis dan squash dengan karakteristik permainan yang relatif mudah dipelajari serta bersifat sosial. Karakteristik tersebut menjadikan padel menarik bagi berbagai kalangan, khususnya generasi muda di wilayah perkotaan. Secara historis, olahraga ini diperkenalkan di Indonesia oleh komunitas ekspatriat sebelum berkembang lebih luas di kota-kota besar (Liputan6.com, 2025). Namun, kehadiran olahraga ini menuai banyak opini dari masyarakat dalam beberapa waktu terakhir. Dengan memanfaatkan analisis sentimen, pengelola olahraga padel dapat menyesuaikan layanan dan fasilitas sesuai dengan preferensi pemain dan masyarakat sekitar, sehingga pada akhirnya dapat meningkatkan loyalitas komunitas serta memperkuat daya saing industri padel.

Dalam analisis sentimen pada konteks olahraga padel, pemilihan metode ekstraksi fitur menjadi aspek krusial. Teknik *TF-IDF* dikenal efektif dalam mengolah data teks seperti ulasan pemain dan komentar media sosial, serta tetap kompetitif pada dataset terbatas (Das & Chakraborty, 2019; Rifaldy et al., 2025). Ketika dikombinasikan dengan algoritma *machine learning*, metode ini mampu menghasilkan klasifikasi sentimen yang baik terkait pengalaman bermain dan kualitas fasilitas padel (Singh et al., 2022). Selain itu, *Named Entity Recognition* (NER) dan *Part-of-Speech* (POS) tagging memberikan insight tambahan dengan mengidentifikasi entitas seperti nama klub, lokasi, dan penyelenggara (Gunawan et al., 2018; Khairunnisa et al., 2020; Wibawa et al., 2016).

Namun, kompleksitas bahasa dalam ulasan dan media digital menuntut pendekatan yang lebih mendalam. Oleh karena itu, penelitian ini menggunakan model *Deep Learning* berbasis BERT melalui *fine-tuning*, dengan pengujian parameter seperti *sequence length*, *learning rate*, serta *training stabilization*. Pendekatan ini bertujuan menghasilkan model klasifikasi sentimen yang akurat dan robust dalam memahami opini publik terhadap perkembangan padel di Indonesia.

Pendekatan eksperimental ini bertujuan untuk menghasilkan model klasifikasi sentimen yang tidak hanya akurat, tetapi juga *robust* dalam memahami dinamika opini publik terhadap perkembangan olahraga padel di Indonesia pada melalui artikel berita terkini yang telah dikumpulkan.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, permasalahan yang akan dikaji dalam penelitian ini adalah sebagai berikut:

1. Bagaimana performa model BERT dalam melakukan klasifikasi sentimen terhadap artikel berita daring berbahasa Indonesia yang membahas olahraga padel di Indonesia?
2. Bagaimana variasi panjang input teks (*max sequence length*) memengaruhi kemampuan model dalam memahami konteks artikel berita olahraga padel serta berdampak pada tingkat akurasi klasifikasi sentimen, mengingat panjang teks berita yang cenderung lebih kompleks dibandingkan media sosial?
3. Bagaimana pengaruh penerapan strategi fine-tuning terhadap stabilitas proses pelatihan dan kinerja akhir model pada domain berita olahraga padel?

1.3 Tujuan Penelitian

Adapun tujuan yang ingin dicapai dari penelitian ini adalah:

1. Mengevaluasi kinerja model IndoBERT yang telah di-fine-tune untuk tugas analisis sentimen pada domain artikel berita daring mengenai olahraga padel di Indonesia.
2. Menganalisis pengaruh batasan panjang input teks terhadap efektivitas model dalam memproses informasi kontekstual pada artikel berita olahraga padel yang memiliki struktur teks panjang dan formal.
3. Menentukan konfigurasi hyperparameter yang optimal, khususnya terkait strategi learning rate dan skema scheduler, untuk menghasilkan model klasifikasi sentimen yang stabil dan akurat pada domain berita olahraga padel.

BAB II

TINJAUAN PUSTAKA

Tinjauan pustaka ini menyajikan rangkuman penelitian-penelitian terdahulu yang relevan dengan topik analisis sentimen artikel berita olahraga padel menggunakan pendekatan fine-tuning model BERT. Kajian literatur mencakup empat klaster utama, yaitu: (1) analisis sentimen pada domain olahraga, (2) analisis sentimen pada teks berita daring, (3) penerapan IndoBERT dan model Transformer untuk analisis sentimen berbahasa Indonesia, serta (4) pertumbuhan olahraga padel dan relevansinya sebagai objek kajian. Tabel 2.1 berikut menyajikan ringkasan hasil penelitian terdahulu yang dijadikan acuan.

Tabel 2.1 Ringkasan Penelitian Terdahulu yang Relevan

No.	Penelitian	Data & Metode	Hasil & Relevansi
1	Adrian et al. (2025) Analisis Sentimen Tim Nasional Indonesia pada AFF 2024 Menggunakan Naive Bayes dan KNN	Data: 1.120 tweet Metode: Naive Bayes & KNN Domain: Olahraga (sepak bola)	KNN menghasilkan akurasi 78,3%, Naive Bayes 74,1%. Studi ini membuktikan bahwa domain olahraga merupakan konteks yang valid dan relevan untuk analisis sentimen berbasis media sosial, namun masih terbatas pada teks pendek dan informal.
2	Rozado, Hughes & Halberstadt (2022) Longitudinal Analysis of Sentiment and Emotion in News Media Headlines Using Transformer Language Models (PLOS ONE)	Data: 23 juta judul berita (2000–2019) Metode: Transformer fine-tuned Domain: Berita daring multitopik	Model Transformer yang di-fine-tune mampu mengklasifikasikan sentimen pada berita daring dengan akurasi tinggi. Studi ini membuktikan relevansi pendekatan Transformer untuk analisis sentimen pada artikel berita formal, serta menunjukkan tren peningkatan negativitas sentimen berita dari waktu ke waktu.
3	Prasetyo et al. (2024) A Comparative Analysis of MultinomialNB, SVM, dan BERT pada Sentimen Twitter Garuda Indonesia (PIKSEL Journal)	Data: 1.250 tweet Garuda Indonesia Metode: MultinomialNB, SVM, BERT Domain: Berita/opini maskapai penerbangan	BERT mencapai akurasi tertinggi (75,6%), mengungguli SVM (71,6%) dan MultinomialNB (64,8%). Penelitian ini menegaskan keunggulan model berbasis Transformer dibanding pendekatan machine learning klasik pada tugas analisis sentimen domain spesifik berbahasa Indonesia.

4	Perwira et al. (2025) Domain-Specific Fine-Tuning of IndoBERT for Aspect-Based Sentiment Analysis in Indonesian Travel User-Generated Content (JISEBI)	Data: Ulasan pariwisata berbahasa Indonesia Metode: Fine-tuning IndoBERT Domain: Pariwisata	IndoBERT yang di-fine-tune secara domain-spesifik mampu mengekstrak aspek dan mengklasifikasikan sentimen pada konten pariwisata dengan efektif. Model menunjukkan performa tinggi untuk sentimen kuat, namun masih perlu ditingkatkan pada sentimen netral dan campuran.
5	Kaswidjanti et al. (2022) Sentiment Analysis of Indonesian Reviews Using Fine-Tuning IndoBERT and R-CNN (ILKOM Jurnal Ilmiah)	Data: Ulasan produk berbahasa Indonesia Metode: Fine-tuning IndoBERT + R-CNN Domain: E-commerce	Kombinasi fine-tuning IndoBERT dan R-CNN menghasilkan peningkatan akurasi yang signifikan dibandingkan model dasar. Penelitian ini memperlihatkan efektivitas fine-tuning IndoBERT pada data ulasan berbahasa Indonesia, sekaligus memberikan landasan metodologis bagi penerapannya di domain lain.
6	Junaidi et al. (2025) Fine Tuning Model IndoBERT untuk Analisis Sentimen Berita Pariwisata Indonesia (Jurnal Pendidikan Teknologi dan Kejuruan, Undiksha)	Data: Berita pariwisata berbahasa Indonesia Metode: Fine-tuning IndoBERT Domain: Berita pariwisata	IndoBERT yang di-fine-tune pada domain berita pariwisata Indonesia mencapai akurasi 77%. Model terbukti mampu mengklasifikasikan sentimen negatif dengan baik, namun masih memerlukan peningkatan pada kelas positif dan netral. Studi ini menjadi referensi terdekat secara domain dan metode dengan penelitian ini.
7	Talaat (2023) Sentiment Analysis Classification System Using Hybrid BERT Models (Journal of Big Data, Springer)	Data: Dataset sentimen multikelas Metode: Hybrid BERT Domain: Umum (media sosial & teks formal)	Model hybrid BERT menunjukkan peningkatan akurasi dibandingkan BERT standar dalam tugas klasifikasi sentimen. Studi ini menegaskan fleksibilitas arsitektur BERT untuk berbagai jenis teks dan tugas klasifikasi sentimen, termasuk domain formal.
8	Wilie et al. (2020) IndoNLU: Benchmark and Resources for Evaluating Indonesian Natural Language	Data: Korpus Indo4B (~4 miliar kata) Metode: Pre-training BERT monolingual Domain: Bahasa Indonesia umum	IndoBERT yang dilatih pada korpus Indo4B mencapai state-of-the-art pada sebagian besar tugas dalam benchmark IndoNLU, mengungguli mBERT dan model multilingual lainnya. Penelitian ini menjadi fondasi utama penggunaan IndoBERT pada

	Understanding (AAACL-IJCNLP 2020)		penelitian NLP berbahasa Indonesia, termasuk studi ini.
--	---	--	--

2.1 Analisis Sentimen pada Domain Olahraga

Penelitian analisis sentimen pada domain olahraga telah berkembang pesat seiring meningkatnya volume data digital yang dihasilkan oleh para penggemar, jurnalis, dan komunitas olahraga di berbagai platform daring. Adrian et al. (2025) menunjukkan bahwa analisis sentimen terhadap tim nasional Indonesia pada turnamen AFF 2024 menggunakan Naive Bayes dan K-Nearest Neighbors (KNN) menghasilkan akurasi yang cukup baik pada data Twitter, dengan KNN mencapai akurasi 78,3%. Penelitian tersebut membuktikan bahwa domain olahraga merupakan konteks yang valid dan informatif untuk kajian analisis sentimen, karena data olahraga sarat dengan opini publik yang bervariasi dan emosional.

Namun, mayoritas studi analisis sentimen olahraga masih terpusat pada platform media sosial, khususnya Twitter/X, yang menghasilkan teks pendek dan informal. Karakteristik ini sangat berbeda dengan artikel berita daring yang bersifat lebih panjang, formal, dan sering mengandung sentimen implisit. Penelitian mengenai sentimen pada teks berita olahraga, termasuk olahraga yang sedang berkembang seperti padel, masih sangat minim. Sehingga, untuk meneliti topik dengan sentimen yang beragam, seperti olahraga padel, pendekatan berbasis Transformer seperti BERT paling relevan untuk menangani kompleksitas teks berita yang lebih tinggi dibandingkan data media sosial.

2.2 Analisis Sentimen pada Teks Berita Daring

Analisis sentimen pada teks berita daring cenderung memiliki kompleksitas yang lebih tinggi dibandingkan teks media sosial karena beberapa faktor khas, yaitu struktur kalimat yang lebih panjang dan formal, dominasi sentimen implisit atau campuran, serta penggunaan ragam bahasa jurnalistik yang kaya akan frasa evaluatif tidak langsung. Rozado et al. (2022) melakukan analisis longitudinal terhadap 23 juta judul berita dari 47 media daring populer di Amerika Serikat menggunakan model Transformer yang di-fine-tune, dan berhasil menunjukkan bahwa pendekatan tersebut efektif untuk mengklasifikasikan sentimen pada artikel berita formal secara otomatis dengan skala besar.

Kajian sistematis terhadap metode NLP untuk klasifikasi sentimen berita daring (IEEE ICCCN, 2023) menegaskan bahwa model berbasis Transformer, khususnya BERT, secara konsisten mengungguli pendekatan berbasis aturan (rule-based) seperti VADER, metode machine learning klasik seperti SVM dan Naive Bayes, serta arsitektur deep learning berbasis RNN, dalam tugas klasifikasi sentimen pada artikel berita formal. Hal ini disebabkan oleh kemampuan mekanisme self-attention pada Transformer untuk menangkap dependensi jangka panjang antar kata, yang sangat krusial pada teks berita dengan paragraf yang panjang dan narasi yang terstruktur.

Prasetyo et al. (2024) yang menganalisis sentimen berita maskapai Garuda Indonesia menggunakan MultinomialNB, SVM, dan BERT pada data Twitter menunjukkan bahwa BERT mencapai akurasi 75,6% dan mengungguli kedua metode lainnya. Meskipun studi tersebut masih berbasis data media sosial, temuan ini memperkuat argumentasi bahwa model Transformer merupakan pilihan superior untuk analisis sentimen pada konten tekstual berbahasa Indonesia yang berkaitan dengan entitas bisnis atau industri tertentu. Pola ini diperkirakan juga berlaku pada analisis sentimen artikel berita olahraga padel.

2.3 IndoBERT dan Fine-Tuning Model Transformer untuk Bahasa Indonesia

Model BERT (Bidirectional Encoder Representations from Transformers) yang diperkenalkan oleh Devlin et al. (2019) pada konferensi NAACL-HLT merupakan tonggak penting dalam perkembangan NLP modern. Arsitektur BERT menggunakan mekanisme self-attention dua arah yang memungkinkan model memahami konteks kata dari kiri maupun kanan secara simultan, berbeda dengan model bahasa sebelumnya yang bersifat unidireksional. Kemampuan ini menjadikan BERT sangat efektif untuk tugas klasifikasi teks, termasuk analisis sentimen, dengan hanya menambahkan satu lapisan output di atas representasi pre-trained dan melakukan proses fine-tuning.

Untuk konteks bahasa Indonesia, Wilie et al. (2020) memperkenalkan IndoBERT melalui makalah IndoNLU yang dipresentasikan pada AACL-IJCNLP 2020. IndoBERT dilatih pada korpus Indo4B yang terdiri dari sekitar empat miliar kata dari berbagai sumber berbahasa Indonesia, termasuk berita daring, media sosial, Wikipedia, dan artikel web. Hasil evaluasi pada dua belas tugas NLP dalam benchmark IndoNLU menunjukkan bahwa IndoBERT secara konsisten mengungguli model multilingual seperti mBERT dan XLM-R pada sebagian besar tugas, yang membuktikan keunggulan model monolingual berbahasa Indonesia dibandingkan model multibahasa untuk pemrosesan teks berbahasa Indonesia.

Berbagai penelitian terkini telah membuktikan efektivitas fine-tuning IndoBERT pada domain spesifik. Perwira et al. (2025) menerapkan fine-tuning IndoBERT secara domain-spesifik untuk analisis sentimen berbasis aspek pada konten pariwisata berbahasa Indonesia dan menunjukkan hasil yang efektif dalam ekstraksi aspek serta klasifikasi sentimen. Kaswidjanti et al. (2022) mengombinasikan fine-tuning IndoBERT dengan R-CNN untuk analisis sentimen ulasan produk berbahasa Indonesia dan memperoleh peningkatan akurasi yang signifikan. Junaidi et al. (2025) secara spesifik menerapkan fine-tuning IndoBERT pada domain berita pariwisata Indonesia dan mencapai akurasi 77%, sekaligus mengidentifikasi tantangan model dalam menangani sentimen positif dan netral pada teks berita formal.

Studi-studi tersebut secara kolektif menegaskan bahwa IndoBERT merupakan model yang paling sesuai untuk analisis sentimen artikel berita berbahasa Indonesia, dan bahwa proses fine-tuning secara domain-spesifik merupakan strategi yang efektif untuk meningkatkan performa model pada domain yang belum pernah dilihat selama fase pre-training. Penelitian ini mengadopsi pendekatan serupa, yaitu fine-tuning IndoBERT-base-p2 pada domain berita

olahraga padel di Indonesia, dengan mengeksplorasi berbagai konfigurasi hyperparameter untuk menemukan konfigurasi yang paling optimal.

2.4 Perkembangan Olahraga Padel dan Relevansinya sebagai Objek Kajian

Di Indonesia, pertumbuhan padel terbilang fenomenal dalam dua tahun terakhir. Pesatnya pertumbuhan padel di Indonesia telah mendorong munculnya pemberitaan yang masif di berbagai portal berita daring nasional, mencakup topik yang beragam mulai dari perkembangan infrastruktur lapangan, profil komunitas pemain, potensi investasi bisnis padel, liputan turnamen, hingga isu aksesibilitas dan regulasi. Fenomena ini menciptakan korpus data teks berita yang kaya dan beragam, sekaligus menjadikan analisis sentimen berita padel sebagai kajian yang relevan dan strategis. Wawasan yang dihasilkan dari analisis sentimen berita padel dapat dimanfaatkan oleh berbagai pemangku kepentingan, termasuk pengelola klub, investor, asosiasi olahraga, dan media, untuk memahami dan merespons dinamika persepsi publik terhadap olahraga ini secara lebih terukur dan berbasis data.


Berdasarkan tinjauan literatur yang telah dilakukan, meskipun analisis sentimen pada domain olahraga telah banyak dilakukan, hampir seluruhnya masih terfokus pada data media sosial berbentuk teks pendek dan informal, sementara analisis sentimen pada artikel berita olahraga formal berbahasa Indonesia masih sangat jarang dieksplorasi. Di sisi lain, olahraga padel sebagai fenomena yang sedang berkembang pesat di Indonesia sama sekali belum pernah menjadi subjek penelitian analisis sentimen, baik di tingkat nasional maupun internasional. Meskipun fine-tuning IndoBERT telah diterapkan pada beberapa domain berbahasa Indonesia seperti ulasan produk, konten pariwisata, dan berita umum, penerapannya pada domain berita olahraga spesifik di Indonesia belum pernah dilakukan. Sehingga, melalui penelitian ini akan dataset berita padel Indonesia akan dimodelkan fine-tuning IndoBERT-base-p2, disertai dengan serangkaian eksperimen teknis untuk mengidentifikasi konfigurasi hyperparameter yang optimal.

BAB III

METODOLOGI

3.1 Metodologi Penelitian

Diagram metode penelitian yang menunjukkan langkah-langkah pengerjaan penelitian ini digambarkan pada gambar berikut ini:



Gambar 3.1 Diagram Metode Penelitian

3.2 Uraian Alur Pelaksanaan Penelitian

Secara umum, metodologi penelitian ini mencakup tiga tahap utama, yaitu persiapan data, pemrosesan data, dan analisis hasil. Berdasarkan diagram alir penelitian (Gambar 3.1), setiap tahapan saling terhubung, di mana keluaran dari satu tahap menjadi masukan bagi tahap berikutnya. Proses penelitian diawali dengan pengumpulan dan pemanfaatan data, yang kemudian diolah menjadi dataset utama untuk melatih model bahasa berbasis BERT dalam analisis sentimen. Penjelasan rinci mengenai mekanisme dan prosedur pada setiap tahap disajikan pada subbab berikutnya.

3.2.1 Akuisisi Data

Pada tahap ini, data diambil untuk dimasukkan ke dalam *dataset* yang berasal dari bahan mentah berita dari sumber internet. Tahapan ini mencakup:

- **Akuisisi Judul & Link Berita:**
Proses awal dilakukan menggunakan Google News RSS untuk mengambil judul artikel, tautan berita, sumber berita, dan tanggal publikasi berdasarkan kata kunci yang telah ditentukan.
- **Akuisisi Data Konten Berita:**
Tautan berita yang diperoleh kemudian diproses menggunakan metode *web scraping* untuk mengambil isi lengkap artikel. Proses scraping dilakukan pada beberapa portal berita seperti Detik, Kompas, Tempo, dan CNN Indonesia menggunakan CSS Selector yang disesuaikan dengan struktur HTML masing-masing website. Pada tahap ini dilakukan juga proses *cleaning* untuk menghapus URL, tag HTML, dan teks yang tidak diperlukan.
- **Bing News Search**
Selain RSS dan scraping langsung, pengambilan data juga dilakukan melalui Bing News Search untuk memperluas sumber berita yang diperoleh.
- **Proses Merge dan Filtering Data**
Seluruh data kemudian digabungkan ke dalam satu dataset dan dilakukan proses *deduplication* serta *filtering* berdasarkan relevansi dan kelengkapan artikel sebelum digunakan pada tahap penelitian selanjutnya.

Adapun struktur dataset yang digunakan dalam penelitian ini ditunjukkan pada tabel berikut.

No.	Nama Kolom	Deskripsi
1	judul	Judul asli artikel berita yang diambil dari sumber RSS Feed.
2	url / link	URL atau tautan unik yang merujuk langsung ke sumber artikel berita asli.

3	sumber / portal_berita	Nama media atau portal berita yang mempublikasikan artikel.
4	tanggal	Tanggal dan waktu publikasi artikel berita.
5	keyword	Kata kunci pencarian yang digunakan saat mengambil artikel dari RSS Feed.
6	metode_scraping	Metode yang digunakan dalam proses pengambilan konten artikel.
7	konten	Isi atau teks lengkap dari artikel berita yang menjadi objek utama analisis.
8	label / label_text	Label hasil klasifikasi sentimen semi-manual: Positif, Netral, atau Negatif.

- **Ekstraksi Konten Artikel**
sistem scraping cepat yang menggunakan *multithreading* untuk menarik isi berita dari 1.847 tautan secara bersamaan lalu membersihkan teksnya dan menggabungkannya dengan judul agar siap diolah untuk analisis data.
- **Penyimpanan Hasil Scrapping**
Artikel yang telah berhasil melalui proses *web scrapping* dan pemrosesan sederhana didapatkan sebanyak 1.847 tautan artikel yang kemudian dilakukan *semi manual cleaning* dan dihasilkan output akhir sebanyak 789 tautan artikel.

3.2.2 Analisis Sentimen Dasar

Tahapan ini bertujuan untuk membangun *ground truth* atau data acuan yang valid pada dataset yang telah dikumpulkan. Karena dataset awal berupa data mentah tanpa label, proses klasifikasi sentimen dilakukan secara semi-manual (*human annotation*) oleh peneliti dengan meninjau setiap baris data. Proses penentuan label didasarkan pada analisis linguistik dan konteks berita dengan kriteria klasifikasi sebagai berikut

- **Sentimen Negatif (0):**
Label ini diberikan kepada teks yang memuat kritik, keluhan warga, kerugian finansial, atau permasalahan hukum yang dihadapi subjek berita
- **Sentimen Netral (1):**
Label ini diberikan kepada teks yang bersifat informatif, faktual, berupa pengumuman, dan tidak memuat emosi subjektif yang dominan.
- **Sentimen Positif (2):**
Label ini diberikan pada teks berita yang mengandung kosakata apresiasi, pencapaian prestasi, promosi terhadap olahraga padel, keuntungan olahraga padel, atau dukungan positif.

3.2.3 Pre-pemrosesan Data

Tahap pra-pemrosesan data dirancang untuk membersihkan dan menstandarkan teks mentah hasil scraping agar siap digunakan pada tahap analisis sentimen. Pada tahap ini, data diolah menggunakan pendekatan klasik NLP untuk mendukung proses analisis sentimen, dengan pendekatan BERT serta TF-IDF. Pendekatan ini dilakukan supaya pra-pemrosesan dapat relevan untuk diimplementasikan ke kedua model yang memiliki kriteria yang cukup berbeda tersebut. Pendekatan fine-tuning model transformer (IndoBERT) tidak memerlukan agresivitas pembersihan teks karena model telah dilatih pada teks alami, sedangkan pada pendekatan berbasis TF-IDF, normalisasi agresif diperlukan untuk mereduksi dimensi fitur dan meningkatkan kualitas representasi. Langkah-langkah pra-pemrosesan yang dilakukan adalah sebagai berikut:

3.2.3.1 Uppercase-to-Lowercase

Seluruh teks artikel dikonversi menjadi huruf kecil (*lowercase*) untuk memastikan konsistensi representasi kata. Tahap ini mencegah model memperlakukan kata yang sama sebagai token berbeda hanya karena perbedaan kapitalisasi, misalnya "Padel" dan "padel".

3.2.3.1 Tokenisasi

Sebelum tokenisasi dilakukan, teks terlebih dahulu melalui tahap **pembersihan HTML Entity** dan karakter ** **; atau karakter non-breaking space yang dapat mengganggu proses tokenisasi. Setelah pembersihan, teks ditokenisasi menggunakan pustaka NLTK. Pada proses tokenisasi ini juga dilakukan penghapusan karakter tunggal yang bukan merupakan digit, karena karakter tersebut umumnya merupakan noise dari hasil scraping atau sisa tanda baca yang tidak bermakna secara linguistik.

3.2.3.1 Penghapusan Stopwords

Penghapusan *stopwords* dilakukan dalam dua tahap untuk memastikan cakupan:

- **NLTK Stopwords:** Daftar *stopwords* bahasa Indonesia bawaan dari pustaka NLTK digunakan sebagai filter pertama. Daftar ini mencakup kata-kata umum seperti "yang", "dan", "di", "ke", dan sejenisnya yang tidak membawa makna kontekstual signifikan.
- **Custom Stopwords:** Setelah inspeksi terhadap 100 kata teratas hasil penghapusan NLTK, ditemukan sejumlah kata yang masih sering muncul namun tidak informatif dalam konteks domain analisis. Kata-kata tersebut kemudian ditambahkan ke daftar *custom stopwords*, meliputi *noise* web/scraping seperti "com", "id", "co", kata-kata terlalu umum seperti "memiliki", "orang", "cocok", satuan dan angka seperti "rp", "ribu", "jam", serta nama platform media seperti "detikers", "detikcom", "tvonenews".

3.2.3.1 Lemmatization

Lemmatisasi atau *stemming* dilakukan menggunakan pustaka PySastrawi, yang merupakan implementasi Python dari algoritma Sastrawi untuk bahasa Indonesia. PySastrawi mengidentifikasi afiks (awalan, akhiran, dan kombinasinya) dan mengembalikan kata ke bentuk dasarnya (kata dasar). Misalnya, kata "memainkan", "dimainkan", dan "permainan" semuanya dikembalikan ke bentuk dasar "main".

3.2.3.1 Penyimpanan Hasil Pemrosesan

Setelah seluruh tahap pra-pemrosesan selesai, hasil akhir disimpan dalam format CSV. File ini menambahkan kolom-kolom baru hasil pra-pemrosesan, yakni *to_lowercase*, *clean_text*, *before_stopwords*, *after_stopwords*, dan *after_lemmatization*. File CSV ini menjadi input utama untuk seluruh tahap analisis selanjutnya, meliputi pemilihan model, fine-tuning, dan ekstraksi fitur.

3.2.4 Pemilihan Model

Tahap ini berfokus pada penentuan arsitektur model yang akan digunakan sebagai landasan (*backbone*) sistem. Model IndoBERT dipilih sebagai model paling optimal yang didasarkan pada tiga pertimbangan utama, yaitu kesesuaian domain bahasa, ukuran model, dan *trade-off* antara performa dan kecepatan.

Dari aspek domain bahasa, IndoBERT dipilih karena model ini dilatih secara khusus menggunakan korpus berbahasa Indonesia dalam skala besar, sehingga representasi semantik yang dihasilkan jauh lebih akurat dibandingkan model multibahasa seperti mBERT (*Multilingual BERT*). IndoBERT mampu menangkap nuansa linguistik, idiom, dan struktur sintaksis khas bahasa Indonesia yang sering kali tidak dapat dipelajari dengan baik oleh model multibahasa yang harus membagi kapasitas representasinya untuk ratusan bahasa sekaligus.

Dari aspek ukuran model, varian *base* yang digunakan pada penelitian ini dipilih karena memberikan keseimbangan antara kedalaman representasi dan efisiensi komputasi. Varian *base* IndoBERT memiliki 12 lapisan transformer dengan 768 dimensi embedding dan sekitar 125 juta parameter, sehingga dapat dijalankan pada GPU dengan memori terbatas maupun CPU tanpa hambatan signifikan. Varian *large*, meskipun berpotensi menghasilkan representasi yang lebih kaya, memerlukan sumber daya komputasi yang jauh lebih besar dan cenderung menghasilkan overfitting pada dataset berukuran kecil.

Dari aspek *trade-off* performa terhadap kecepatan, model apriandito/indobert-sentiment-classifier merupakan model IndoBERT yang telah melalui fine-tuning awal pada tugas klasifikasi sentimen bahasa Indonesia. Hal ini berarti model sudah memiliki bobot yang relatif teradaptasi untuk tugas tersebut, sehingga konvergensi lebih cepat dan inferensi lebih efisien dibandingkan melatih model dari awal.

3.2.5 Fine-Tuning Model

Pada tahap ini, model IndoBERT yang telah dipilih diterapkan untuk melakukan inferensi sentimen pada seluruh dataset. Proses ini mencakup beberapa sub-tahap:

3.2.5.1 Exploratory Data Analysis (EDA)

Sebelum model diterapkan, dilakukan *Exploratory Data Analysis* (EDA) untuk memahami karakteristik dataset. EDA melihat distribusi artikel per portal berita, distribusi label manual yang telah ditetapkan pada tahap analisis sentimen dasar, serta statistik deskriptif mengenai panjang teks dan sebaran temporal artikel. Informasi ini digunakan untuk mendeteksi ketidakseimbangan kelas dan merencanakan strategi inferensi yang sesuai.

3.2.5.2 Pemuatan Model dan Tokenizer

Pada tahap ini, model *pre-trained* apriandito/indobert-sentiment-classifier dan tokenizer yang sesuai dimuat menggunakan API *AutoModelForSequenceClassification* dan *AutoTokenizer* dari pustaka *Hugging Face Transformers*.

3.2.5.3 Pengaturan Konteks

Untuk meningkatkan performa prediksi, konteks ditambahkan untuk memberikan informasi tambahan kepada model tentang jenis teks yang akan dianalisis sentimennya. Ini membantu model dalam memahami nuansa tertentu dari domain berita Padel.

3.2.5.4 Prediksi Sentimen

Fungsi `predict_sentiment()` dirancang untuk melakukan inferensi secara batch demi efisiensi. Fungsi ini menerima sekumpulan teks, menggabungkan setiap teks dengan konteks dalam format yang ditentukan, dan memprosesnya melalui tokenizer dengan parameter `truncation=True` dan `max_length=256` untuk memastikan panjang input tidak melampaui kapasitas model. Logits yang dihasilkan oleh model kemudian dikonversi menjadi probabilitas menggunakan fungsi `softmax`, dan kelas dengan probabilitas tertinggi dipilih sebagai prediksi sentimen beserta skor kepercayaannya.

3.2.5.5 Penerapan pada Dataset dan Penyimpanan Hasil

Fungsi prediksi diterapkan pada kolom judul dan konten dari DataFrame dataset. Hasil prediksi, berupa label sentimen mentah (POSITIF, NETRAL, atau NEGATIF) dan skor kepercayaan, disimpan dalam kolom baru `before_stopwords`, `after_stopwords`, `after_lemmatization` sebagai hasil akhir analisis.

3.2.6 Ekstraksi Fitur

Tahap ekstraksi fitur bertujuan untuk mengidentifikasi pola linguistik dan topik signifikan dari corpus menggunakan beberapa metode, antara lain:

3.2.6.1 Analisis TF-IDF

Term Frequency-Inverse Document Frequency (TF-IDF) digunakan untuk mengidentifikasi kata-kata yang paling signifikan dan diskriminatif dalam corpus. Analisis TF-IDF dilakukan pada empat level granularitas:

- **TF-IDF Keseluruhan Korpus:** Mengidentifikasi kata-kata paling dominan secara global di seluruh dataset untuk memahami topik utama yang dibahas.
- **TF-IDF per Kanal Berita:** Membandingkan kata-kata signifikan antar portal berita untuk mengidentifikasi perbedaan fokus dan gaya pelaporan masing-masing sumber.
- **TF-IDF per Bulan:** Melacak perubahan kata-kata signifikan dari waktu ke waktu untuk memahami evolusi topik dan tren pemberitaan secara temporal.
- **TF-IDF per *Keywords*:** Mengidentifikasi kata-kata yang paling khas untuk setiap kata kunci yang digunakan dalam proses scraping, untuk memvalidasi relevansi artikel yang dikumpulkan.

3.2.6.2 POS Tagging

Part-of-Speech (POS) Tagging dilakukan menggunakan pustaka Stanza. Stanza dipilih karena menyediakan model yang akurat untuk bahasa Indonesia dan mendukung *pipeline* yang mencakup tokenisasi, lemmatisasi, POS tagging, dan *dependency parsing* secara terintegrasi. POS tagging memungkinkan identifikasi jenis kata (kata benda, kata sifat, kata kerja, dll.) dalam setiap artikel untuk memahami struktur linguistik teks dan mengidentifikasi kata-kata yang paling informatif.

3.2.6.3 Named Entity Recognition (NER)

Named Entity Recognition (NER) juga diterapkan menggunakan *pipeline* Stanza yang sama dengan POS tagging, memanfaatkan model NER bahasa Indonesia yang tersedia. NER bertujuan untuk mengidentifikasi dan mengklasifikasikan entitas bernama dalam teks, seperti nama orang, organisasi, lokasi, dan waktu.

3.2.6.4 Analisis N-gram

Analisis N-gram, khususnya bigram (pasangan kata berurutan), dilakukan untuk mengidentifikasi frasa-frasa yang signifikan dan sering muncul bersama dalam corpus. Analisis ini dilakukan per dimensi waktu (per bulan) untuk melacak bagaimana frasa-frasa penting berevolusi seiring perkembangan pemberitaan.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Hasil Akuisisi Data

Tahap akuisisi data bertujuan untuk mengumpulkan corpus berita berbahasa Indonesia sesuai dengan topik ‘**Olahraga Padel**’. Proses ini dilakukan menggunakan metode web scraping melalui *RSS Feed Google News*, *RSS Direct Feed*, dan *RSS Bing Search* dengan bantuan skrip *Python* yang berjalan secara otomatis.

4.1.1 Hasil Akuisisi *RSS Feed Google News*

Akuisisi data yang pertama diambil dari *Google News RSS Feed* menggunakan fungsi *scrape_google_news* yang dipanggil melalui *fetch_google*. Tahap ini mencari berita berdasarkan *keywords* yang telah ditentukan, dengan rentang waktu 180 hari dan 365 hari. Total artikel yang berhasil dikumpulkan dari *Google News RSS* adalah **6070**. Berikut adalah beberapa data yang berhasil diambil:

Gambar 4.1 Hasil Akuisisi *RSS Feed Google News*

Google News RSS							
	judul	url	sumber	tanggal	ringkasan	keyword	metode_scraping
0	Masa depan padel: Antara gengsi atau turun kel...	https://news.google.com/rss/articles/CBMiqAFBV...	The Conversation	2026-03-04 08:00:00	Masa depan padel: Antara gengsi atau turun kel...	lapangan padel	google_news_180d
1	206 Lapangan Padel di Jakarta Disanksi Adminis...	https://news.google.com/rss/articles/CBMilgFBV...	Beritajakarta.id	2026-03-06 08:00:00	206 Lapangan Padel di Jakarta Disanksi Adminis...	lapangan padel	google_news_180d
2	Pemprov DKI Larang Pembangunan Lapangan Padel ...	https://news.google.com/rss/articles/CBMisgFBV...	Hukumonline	2026-02-24 08:00:00	Pemprov DKI Larang Pembangunan Lapangan Padel ...	lapangan padel	google_news_180d
3	Tren Olahraga Padel Mewabah di Kota Tangerang,...	https://news.google.com/rss/articles/CBMi4AFBV...	Pemerintah Kota Tangerang	2026-01-09 08:00:00	Tren Olahraga Padel Mewabah di Kota Tangerang,...	lapangan padel	google_news_180d
4	Aktivitas Lapangan Padel Dianggap Mengganggu, ...	https://news.google.com/rss/articles/CBMitwFBV...	Dewan Perwakilan Rakyat Daerah Kota Bandung	2026-04-29 20:33:35	Aktivitas Lapangan Padel Dianggap Mengganggu, ...	lapangan padel	google_news_180d

4.1.2 Hasil Akuisisi *RSS Direct Feed*

Untuk web scraping, fungsi *scrape_site* dan *fetch_site* digunakan untuk mencari artikel dari portal-portal berita yang populer, seperti Detik.com, Kompas.com, Tempo.co, dan CNN Indonesia. Setiap situs memiliki fungsi URL dan *domain check*-nya masing-masing untuk memastikan relevansi artikel. Total artikel yang berhasil dikumpulkan dari web scraping ini adalah **4908**.

Gambar 4.2 Hasil Akuisisi *RSS Direct Feed (Web Scrapping)*

Web Scrapping:

	judul	url	sumber	tanggal	ringkasan	keyword	metode_scraping
0	BNN Dorong Generasi Muda Hidup Sehat Lewat Tur...	https://news.detik.com/berita/d-8473825/bnn-do...	Detik.com			olahraga padel	detik_search
1	Begini Kondisi Purbaya Usai Heboh Kabar Masuk ...	https://finance.detik.com/berita-ekonomi-bisni...	Detik.com			olahraga padel	detik_search
2	PBPI Kota Kediri Resmi Dilantik, Ini Pesan Wal...	https://www.detik.com/jatim/berita/d-8470579/p...	Detik.com			olahraga padel	detik_search
3	Lewat Padel Tournament, BNN Kampanye Anti-Nark...	https://news.detik.com/adv-nhl-detikcom/d-8470...	Detik.com			olahraga padel	detik_search
4	Olahraga Lari-Padel Berpotensi Picu Risiko Sar...	https://health.detik.com/berita-detikhealth/d-...	Detik.com			olahraga padel	detik_search

4.1.3 Hasil Akuisisi *RSS Bing News Search*

Langkah terakhir dalam akuisisi data adalah *scraping* hasil pencarian *Bing News* menggunakan fungsi *scrape_bing_news*. Penambahan metode ini ditujukan untuk menambah sumber berita padel dengan total artikel yang berhasil dikumpulkan dari Bing News Search adalah **948**.

Gambar 4.3 Hasil Akuisisi *RSS Bing News Search*

Bing News Search

	judul	url	sumber	tanggal	ringkasan	keyword	metode_scraping
0	80 Lapangan Padel Terdata, Satpol PP Tangsel M...	https://bantendaily.id/80-lapangan-padel-terda...	Bing News			padel	bing_news
1	Tren Olahraga Dorong Gaya Hidup Positif, BNN G...	https://news.republika.co.id/berita/tej03u2330...	Bing News			padel	bing_news
2	Diikuti 140 Peserta HKBP Gelar Turnamen Jakart...	https://news.republika.co.id/berita/tegtl456/...	Bing News			padel	bing_news
3	Event Padel Paling Hype! Hi Kiddult Tournament...	https://www.inews.id/sport/all-sport/event-pad...	Bing News			padel	bing_news
4	Gairahkan Olahraga, Senam Zumba Buka Tempat Pa...	https://harian.disway.id/read/944606/gairahkan...	Bing News			padel	bing_news

4.1.4 Hasil Akuisisi *Merge dan Deduplikasi*

Dari proses tersebut, berhasil didapatkan data yang berisi berita terkait padel dari rentang waktu 7 Mei 2025 (07:00:00) hingga 4 Mei (10:57:27). Setelah mengumpulkan data dari ketiga sumber (*Google News RSS*, *Web Scrapping*, dan *Bing News Search*), semua artikel digabungkan menjadi satu *DataFrame*. Kemudian data tersebut dideduplikasi untuk menghilangkan artikel ganda berdasarkan URL dan judul. Kemudian, artikel juga difilter agar hanya menyertakan artikel dengan panjang judul lebih dari 10 karakter. Dari total 11926 artikel sebelum deduplikasi, setelah proses merge dan deduplikasi, didapatkan **3000** artikel yang siap untuk diproseskan lebih lanjut.

Gambar 4.4 Hasil Deduplikasi dan Distribusi Portal Berita

	sumber	
	Kompas.com	1019
	Detik.com	330
	tvOneNews	75
	Bolasport.com	73
	Bing News	61
	RRI.co.id	47
	detiksport	32
	MetroTVNews.com	30
	Kumparan.com	27
	Tempo.co	26
	Suara.com	26
	detikcom	23
	detikNews	22
	Beritajakarta.id	20
	Kompas.id	18
Total before dedup	:	11926
Google News RSS	:	6070
Web Scrapping	:	4908
Bing News	:	948
Total after dedup	:	3000

Gambar 4.5 Hasil Akuisisi *RSS Bing News Search*

Merged & Deduplicated DataFrame											
	judul	url	sumber	tanggal	ringkasan	keyword	metode_scraping	konten_bersih	judul_bersih	teks_analisis	konten
0	Libur Idulfitri Viral: Taman Bendera Pusaka Di...	https://news.google.com/rss/articles/CBMiwwFBV...	bisnismarket.com	2026-03-23 07:00:00	Libur Idulfitri Viral: Taman Bendera Pusaka Di...	padel viral	google_news_180d	libur idulfitri viral taman bendera pusaka dis...	libur idulfitri viral taman bendera pusaka dis...	libur idulfitri viral taman bendera pusaka dis...	Libur Idulfitri Viral: Taman Bendera Pusaka Di...
1	Zulfikar Maulana Dapat Dukungan Maju sebagai K...	https://news.google.com/rss/articles/CBMingFBV...	sport.truestory.id	2026-01-11 08:00:00	Zulfikar Maulana Dapat Dukungan Maju sebagai K...	padel sport	google_news_180d	zulfikar maulana dapat dukungan maju sebagai k...	zulfikar maulana dapat dukungan maju sebagai k...	zulfikar maulana dapat dukungan maju sebagai k...	Zulfikar Maulana Dapat Dukungan Maju sebagai K...
2	Asian Games Pun Akan Terpadel-padel - Kompas.id	https://news.google.com/rss/articles/CBMic0FVK...	Kompas.id	2025-11-15 08:00:00	Asian Games Pun Akan Terpadel-padel p...	padel Indonesia	google_news_180d	asian games pun akan terpadel pnsrpkomp...	asian games pun akan terpadel kompasid	asian games pun akan terpadel kompasid a...	Asian Games Pun Akan Terpadel-padel p...
3	Ratasan Lapangan Padel di Jakarta Selatan Tern...	https://news.google.com/rss/articles/CBMiuwFBV...	jakrev.com	2026-03-16 07:00:00	Ratasan Lapangan Padel di Jakarta Selatan Tern...	investasi padel	google_news_180d	ratasan lapangan padel di jakarta selatan tern...	ratasan lapangan padel di jakarta selatan tern...	ratasan lapangan padel di jakarta selatan tern...	Ratasan Lapangan Padel di Jakarta Selatan Tern...
4	Disegel, Lapangan Padel di Jaktim Pakai Izin K...	https://news.google.com/rss/articles/CBMirAFBV...	detikNews	2026-03-14 07:00:00	Disegel, Lapangan Padel di Jaktim Pakai Izin K...	lapangan padel Jakarta	google_news_180d	disegel lapangan padel di jaktim pakai izin ko...	disegel lapangan padel di jaktim pakai izin ko...	disegel lapangan padel di jaktim pakai izin ko...	Disegel, Lapangan Padel di Jaktim Pakai Izin K...

4.1.4 Hasil Validasi Data & Semi-Manual Labeling

Semua data yang telah terkumpul dan digabungkan di-*export* menjadi file *csv*, yang selanjutnya divalidasi kembali relevansinya secara semi-manual kembali untuk dibersihkan apabila ada data-data yang masih kosong atau sangat tidak relevan (karena salah terbaca *tag*). Hasil berita yang didapatkan setelah *cleaning* secara manual adalah **798** artikel. Setelah itu, data yang sudah bersih diberi labeling sentimen positif, netral, dan negatif.

Gambar 4.6 Hasil Artikel Padel yang Sudah di-*cleaning*

[illegible]

4.2 Hasil Pra-Pemrosesan Data

Dari data yang sudah dibersihkan pada tahap sebelumnya, sebelum dimodelkan dengan BERT maupun TF-IDF, data-data tersebut perlu melalui proses pre-pemrosesan yang terdiri dari beberapa tahap. Tahap-tahap pra-pemrosesan data menggunakan pendekatan NLP klasik, mencakup *Uppercase-to-Lowercase*, *Tokenization*, *Stopwords Removal*, dan *Lemmatization*.

Untuk *custom stopwords*, kami terlebih dahulu mengidentifikasi kata-kata apa yang kurang signifikan, namun masih masuk dalam top 100 kata dengan kode berikut:

Gambar 4.9 Daftar dan Kode *Custom Stopwords*

```
additional_stopwords = [  
    # Noise web / scraping  
    'com', 'id', 'co', 'scroll', 'continue', 'with', 'content', 'to', 'the',  
  
    # Satuan / angka / umum banget  
    'rp', 'ribu', 'jam', 'nomor', 'area',  
  
    # Kata terlalu umum (tidak spesifik insight)  
    'memiliki', 'salah', 'orang', 'ya', 'cocok', 'nyaman', 'membantu',  
    'pilihan', 'terbaik', 'mudah', 'aktif', 'sesuai',  
  
    # Kata generik aktivitas  
    'kegiatan', 'aktivitas', 'gaya', 'hidup',  
  
    # Kata lokasi terlalu umum (opsional, tergantung analisis)  
    'kota', 'daerah', 'kawasan', 'jalan', 'selatan', 'timur',  
  
    # Kata media / platform  
    'detikers', 'detikcom', 'tvonenews', 'artikel', 'video', 'instagram',  
  
    # Kata kurang informatif dalam konteks  
    'suara', 'izin', 'malam', 'kali', ' ', '""', '"com"', "id"  
]
```

Gambar 4.9 Hasil *Stopwords Removal*

Total stopwords (NLTK + custom): 805

```
=== Sample: before_stopwords ===  
['riset', 'laju', 'properti', '2026', 'moderat', 'lapangan', 'padel', 'justru', 'meningkat', 'cnn', 'indonesia']  
  
=== Sample: after_stopwords ===  
['riset', 'laju', 'properti', '2026', 'moderat', 'lapangan', 'padel', 'meningkat', 'cnn', 'indonesia']
```

4.2.3 Hasil *Lemmatization*

Lemmatization adalah tahap terakhir dari pra-pemrosesan yang kami lakukan. Fitur ini mengubah kata-kata menjadi bentuk dasarnya atau akar kata (*lemma*) berdasarkan makna leksikalnya. Misalnya, "bermain", "memainkan", atau "dimainkan" akan dikembalikan menjadi "main". Proses ini menggunakan *library Sastrawi*, khususnya *StemmerFactory* untuk bahasa Indonesia.

Gambar 4.11 Hasil *Lemmatization*

```
=== Sample: after_stopwords ===  
['riset', 'laju', 'properti', '2026', 'moderat', 'lapangan', 'padel', 'meningkat', 'cnn', 'indonesia']  
  
=== Sample: after_lemmatization ===  
['riset', 'laju', 'properti', '2026', 'moderat', 'lapang', 'padel', 'tingkat', 'cnn', 'indonesia']
```


4.3 Hasil *Fine-Tuning* dengan Menggunakan IndoBERT

Selanjutnya, dilakukan analisis sentimen dari untuk menentukan tone emosional dalam artikel-artikel Padel ini, untuk memahami sikap, opini, dan emosi yang diekspresikan dalam teks apakah cenderung bernada positif, netral, atau negatif.

4.3.1 Hasil *Exploratory Data Analysis (EDA)*

Sebelum masuk ke tahap pemodelan IndoBERT, kami melakukan *Exploratory Data Analysis* (EDA) untuk mendapatkan insight dari data yang sudah di pra-proseskan. Didapatkan informasi mengenai persebaran artikel per portal berita, dengan portal Detik.com sebagai penyumbang artikel padel terbanyak. Dari EDA ini juga didapat informasi mengenai persebaran sentimen *labeling* data artikel yang dilakukan secara *semi-manual* di tahap sebelumnya dan didapat persebaran artikel dengan tone netral sebanyak 711 artikel, positif sebanyak 70 artikel, dan negatif sebanyak 8 artikel.

Gambar 4.11 Hasil *Exploratory Data Analysis* (EDA) setelah *Pre-Processing*



4.3.2 Hasil Model BERT

Untuk melihat analisis sentimen dalam topik ‘Olahraga Padel’, pada penelitian ini kami menggunakan model IndoBERT dari *apriandito/indobert-sentiment-classifier* dengan bantuan library *transformers* dari *Hugging Face* dan *torch*. Dalam proses prediksi, teks artikel diproses menggunakan teknik tokenisasi sebelum dimasukkan ke dalam model IndoBERT. Untuk meningkatkan relevansi prediksi terhadap topik penelitian, model diberikan konteks tambahan berupa frasa ‘Olahraga Padel’, sehingga format input menjadi [CLS] Olahraga Padel [SEP] teks berita [SEP]. Setelah teks diproses, model menghasilkan logits atau skor mentah untuk setiap kelas sentimen. Skor tersebut kemudian dikonversi menjadi probabilitas menggunakan fungsi *softmax*, dan kelas dengan probabilitas tertinggi dipilih sebagai hasil prediksi sentimen. Selain itu, setiap hasil prediksi juga dilengkapi dengan nilai *confidence score* yang menunjukkan tingkat keyakinan model terhadap klasifikasi yang diberikan.

Gambar 4.12 Kode Pemodelan dengan IndoBERT

```
MODEL_NAME = "apriandito/indobert-sentiment-classifier"
print(f>Loading: {MODEL_NAME}")

tokenizer = AutoTokenizer.from_pretrained(MODEL_NAME)
model_sa = AutoModelForSequenceClassification.from_pretrained(MODEL_NAME)
model_sa.to(torch_device)
model_sa.eval()

LABEL_IDX = {int(k): v for k, v in model_sa.config.id2label.items()}
LABEL_MAP = {'POSITIF': 'Positif', 'NETRAL': 'Netral', 'NEGATIF': 'Negatif'}
print("Label mapping:", LABEL_IDX)
print("Model loaded.")

CONTEXT = "Olahraga Padel"


def predict_sentiment(texts, batch_size=16):
    """Inference with context-conditioned input: [CLS] context [SEP] text [SEP]."""
    results = []
    for i in tqdm(range(0, len(texts), batch_size), desc="Predicting"):
        batch = texts[i : i + batch_size]
        batch = [t if isinstance(t, str) and len(t) > 0 else "tidak ada teks" for t in batch]
        encodings = tokenizer(
            [CONTEXT] * len(batch),
            batch,
            truncation=True,
            max_length=256,
            padding=True,
            return_tensors="pt",
        ).to(torch_device)
        with torch.no_grad():
            logits = model_sa(**encodings).logits
            probs = torch.softmax(logits, dim=-1)
            preds = torch.argmax(probs, dim=-1)
            scores = probs[range(len(batch)), preds]
        for pred, score in zip(preds.cpu().numpy(), scores.cpu().numpy()):
            results.append({"label": LABEL_IDX[int(pred)], "score": float(score)})
    return results

texts = (df['judul'].fillna('') + ' ' + df['konten'].fillna('')).tolist()
raw_preds = predict_sentiment(texts)

df['pred_label_raw'] = [p['label'] for p in raw_preds]
df['pred_score'] = [p['score'] for p in raw_preds]
df['pred_sentiment'] = df['pred_label_raw'].map(LABEL_MAP)

print("\nDistribusi prediksi sentimen:")
print(df['pred_sentiment'].value_counts())
```


Gambar 4.13 Hasil Analisis Sentimen dengan IndoBERT



Hasil analisis menunjukkan bahwa mayoritas besar pemberitaan mengenai padel memiliki sentimen netral. Dari total 789 artikel yang dianalisis, sebanyak 755 artikel atau sekitar 95,7% diklasifikasikan sebagai netral. Temuan ini mengindikasikan bahwa sebagian besar berita tentang padel bersifat informatif dan faktual, tanpa memuat opini atau ekspresi emosional yang

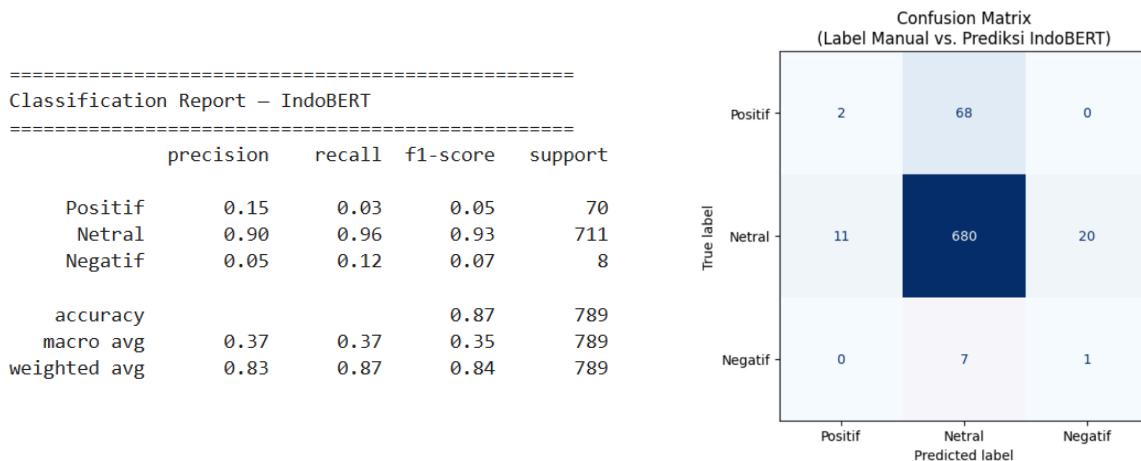
kuat. Sementara itu, artikel dengan sentimen positif hanya berjumlah 13 artikel atau sekitar 1,6%, sedangkan artikel dengan sentimen negatif berjumlah 21 artikel atau sekitar 2,7%. Meskipun jumlah artikel negatif sedikit lebih banyak dibandingkan artikel positif, kedua kategori tersebut tetap merupakan minoritas yang sangat kecil dibandingkan dominasi sentimen netral.

Gambar 4.14 Hasil Distribusi Sentimen per Portal Berita



Dari visualisasi distribusi sentimen per portal berita juga kurang lebih sama seperti analisis sentimen keseluruhan, yang menunjukkan dominasi sentimen Netral. Ini menegaskan bahwa pemberitaan tentang Padel cenderung bersifat informatif dan objektif, bukan provokatif.

Gambar 4.13 Hasil Performa Model IndoBERT



Evaluasi performa model menunjukkan bahwa model memiliki tingkat akurasi keseluruhan sebesar **87%**. Secara umum, angka ini menunjukkan performa yang cukup baik dalam melakukan klasifikasi sentimen. Namun, tingginya akurasi tersebut sangat dipengaruhi oleh dominasi kelas netral dalam dataset. Ketidakseimbangan distribusi data menyebabkan model cenderung memprediksi sebagian besar data sebagai netral. Hal ini terlihat pada hasil

classification report, di mana performa model untuk kelas positif dan negatif masih rendah. Pada kelas positif, nilai precision hanya mencapai 0,15 dan recall sebesar 0,03, yang menunjukkan bahwa model hampir tidak mampu mendeteksi sentimen positif dengan baik. Kondisi serupa juga terjadi pada kelas negatif, dengan precision sebesar 0,05 dan recall sebesar 0,12. Selain itu, nilai **macro average F1-score** sebesar **0,35** menunjukkan bahwa kemampuan model dalam mengklasifikasikan kelas minoritas masih kurang optimal. Dengan demikian, dapat disimpulkan bahwa meskipun model cukup efektif dalam mengenali berita yang bersifat netral, model masih mengalami kesulitan dalam mengidentifikasi sentimen positif maupun negatif akibat ketidakseimbangan data yang sangat tinggi.

4.3.3 Hasil Analisis TF-IDF

Analisis TF-IDF (Term Frequency–Inverse Document Frequency) dilakukan untuk mengidentifikasi kata atau frasa yang paling penting dan relevan dalam kumpulan berita tentang olahraga padel. Proses analisis dilakukan menggunakan library *scikit-learn*, khususnya *TfidfVectorizer*.

Gambar 4.14 *Initial Code* untuk Analisis TF-IDF

```
import pandas as pd
from sklearn.feature_extraction.text import TfidfVectorizer

def tfidf_per_group(
    df,
    text_col,
    group_col,
    top_n=10,
    ngram_range=(1,1),
    min_df=2,
    max_df=0.9,
    stop_words=None
):
    """
    TF-IDF per group (optimized & memory-efficient)
    """

    # Gabungkan teks per group
    grouped = (
        df.groupby(group_col)[text_col]
        .apply(lambda x: ' '.join(x.dropna().astype(str)))
        .reset_index()
    )

    # Buang teks kosong
    grouped = grouped[grouped[text_col].str.strip() != '']

    if grouped.empty:
        print('No data after grouping.')
        return pd.DataFrame()

    # TF-IDF
    vectorizer = TfidfVectorizer(
        ngram_range=ngram_range,
        min_df=min_df,
        max_df=max_df,
        stop_words=stop_words
    )

    tfidf_matrix = vectorizer.fit_transform(grouped[text_col])
    features = vectorizer.get_feature_names_out()

    rows = []

    # Ambil top terms tanpa convert ke dense matrix
    for i, label in enumerate(grouped[group_col]):
        row = tfidf_matrix[i]

        if row.nnz == 0:
            continue

        top_idx = row.data.argsort()[::-1][:top_n]
        top_features = row.indices[top_idx]
        top_scores = row.data[top_idx]

        for rank, (idx, score) in enumerate(zip(top_features, top_scores), 1):
            rows.append({
                group_col: label,
                'rank': rank,
                'term': features[idx],
                'tfidf': round(float(score), 4)
            })

    result = pd.DataFrame(rows)
    if result.empty:
        print('No TF-IDF results.')
        return result

    pivot = result.pivot(index='rank', columns=group_col, values='term')
    return pivot
```

Kode tersebut bertujuan untuk menghitung skor TF-IDF untuk istilah-istilah dalam teks, dikelompokkan berdasarkan kolom tertentu (portal berita, bulan, atau *keywords*). Selanjutnya, kode untuk menganalisis TF-IDF juga dilengkapi dengan fungsi *show_top_words* untuk menampilkan *top_n* kata-kata dengan skor TF-IDF tertinggi untuk setiap grup yang dihasilkan

oleh fungsi *tfidf_per_group*. Ini membantu memvisualisasikan kata kunci yang paling signifikan per kategori.


Gambar 4.15 *show_top_words Function Code*

```
def show_top_words(df_tfidf_results, group_col, title, top_n=10):  
    """  
    Displays the top N TF-IDF terms for each group from the tfidf_per_group DataFrame.  
    """  
    unique_groups = df_tfidf_results[group_col].unique()  
  
    print(f'\n=== {title} ===')  
    for group_name in unique_groups:  
        print(f'\n--- Group: {group_name} ---')  
        top_terms = df_tfidf_results[  
            (df_tfidf_results[group_col] == group_name)  
        ].sort_values('rank').head(top_n)  
        for _, row in top_terms.iterrows():  
            print(f"- {row['term']}: {row['tfidf']:.4f}")
```

4.3.3.1 Hasil TF-IDF Keseluruhan Korpus

TF-IDF keseluruhan korpus bertujuan untuk mengetahui kata-kata yang paling dominan dalam seluruh kumpulan artikel berita padel. Berdasarkan hasil analisis, kata-kata seperti padel, lapang, turnamen, raket, olahraga, jakarta, indonesia, rekomendasi, main, dan atlet memiliki skor TF-IDF tertinggi. Hasil ini menunjukkan bahwa pemberitaan banyak berfokus pada olahraga padel, fasilitas lapangan, perlengkapan, turnamen, serta atlet dan lokasi terkait. Berikut merupakan hasil TF-IDF dari seluruh artikel di masing-masing sentimen.

Gambar 4.16 Hasil TF-IDF 15 Kata Paling Signifikan per Kelas Sentimen



Dari analisis tersebut dapat didapat *insight* bahwa berita dengan sentimen positif banyak membahas kata-kata yang terkait dengan ‘turnamen’, ‘olahraga’, ‘gratis’, ‘sehat’, serta ‘ajak masyarakat’. Apabila kita lihat di netral, artikel banyak membahas tentang teknis dan rekomendasi jika kita lihat dari top 15 kata dari TF-IDF-nya, seperti ‘raket’, ‘lapang’, ‘rekomendasi’, dan ‘main’. Sedangkan, untuk artikel dengan sentimen negatif banyak menyinggung tentang ‘keluh’, ‘mukim’, ‘bangun’, ‘warga’, serta ‘batas’.

4.3.3.2 Hasil TF-IDF per Kanal Berita

Analisis TF-IDF dilakukan secara terpisah untuk setiap portal berita yang memiliki minimal dua artikel dalam corpus. Kode di bawah menghitung jumlah artikel per portal berita, dan memfilter portal berita yang memiliki setidaknya 2 artikel untuk memastikan analisis TF-IDF yang bermakna.

Gambar 4.17 Kode dan Hasil *Filtering* Portal Berita

```
df = df.rename(columns={'sumber': 'portal_berita'})
sumber_counts = df['portal_berita'].value_counts()
print('Articles per source:')
print(sumber_counts.to_string())

# Use sources with >= 2 articles for meaningful TF-IDF
valid_sumber = sumber_counts[sumber_counts >= 2].index.tolist()
df_kanal = df[df['portal_berita'].isin(valid_sumber)]
```

Articles per source:	
portal_berita	
Detik.com	121
tvOneNews	49
Kompas.com	30
MetroTVNews.com	23
RRI.co.id	15
Kumparan.com	15
detikNews	14
Liputan6.com	14
detiksport	12
Tempo.co	11
Bing News	11
ANTARA News	10
Bolasport.com	10
Beritajakarta.id	9
CNN Indonesia	8
Suara Merdeka	8
Bloomberg Technoz	8
Suara.com	8
detikcom	7
Bola.com	7
JPNN.com	7
TripZilla Indonesia	6
MSN	6
iNews.ID	6
KONTAN	5
SinPo.id	5
KapanLagi.com	5
20detik	5

Selanjutnya, dari masing-masing portal berita akan diidentifikasi 10 kata-kata kunci TF-IDF dengan teks yang sudah dilematisasi. Hasil ini menunjukkan kata-kata yang paling khas dan diskriminatif untuk setiap sumber berita, yang mencerminkan perbedaan fokus editorial dan gaya pelaporan masing-masing portal. Gambar 4.17 menampilkan perbandingan top kata TF-IDF antar portal berita.

Gambar 4.17 Hasil Top 10 TF-IDF per Portal Berita

```

=== Top 10 TF-IDF Words per Kanal Berita ===

--- Group: 20detik ---
- 20detik: 0.7083
- bogor: 0.2508
- ledak: 0.2294
- bising: 0.1952
- sd: 0.1417
- narkoba: 0.1417
- lapang: 0.1413
- janji: 0.1325
- kondisi: 0.1325
- saksi: 0.1325

--- Group: ANTARA Foto ---
- foto: 0.7613
- redam: 0.3482
- mukim: 0.3239
- pasang: 0.3138
- warga: 0.2469
- turnamen: 0.1528
- lapang: 0.1072

--- Group: ANTARA News ---
- news: 0.8156
- legislator: 0.1807
- tertib: 0.1564
- turnamen: 0.1373
- galih: 0.0966
- kartasasmita: 0.0966
- pabrik: 0.0966
- langgan: 0.0966
- pangkalpinang: 0.0966
- lapang: 0.0964

--- Group: ANTARA News Megapolitan ---
- news: 0.6464
- legislator: 0.3580
- tegas: 0.1914
- sorot: 0.1914
- transparan: 0.1790
- bca: 0.1790
- tata: 0.1694
- slf: 0.1694
- banyak: 0.1616
- tutup: 0.1492

--- Group: Bangkapos.com ---
- pangkalpinang: 0.6150
- sewa: 0.4126
- com: 0.3117
- khawatir: 0.3075
- biaya: 0.2876
- mula: 0.1964
- buka: 0.1801
- hadir: 0.1766
- resmi: 0.1732
- lapang: 0.1534

--- Group: Berita Nasional - Media Pencerah Bangsa ---
- cerah: 0.3903
- golkar: 0.3651
- bangsa: 0.3651
- berita: 0.3651
- media: 0.3044
- nasional: 0.2689
- bahlil: 0.1728
- sama: 0.1728
- syarat: 0.1728
- cinta: 0.1581

--- Group: BeritaJateng.id ---
- kalong: 0.5143
- walkot: 0.5143
- id: 0.2650
- atlet: 0.2485
- pon: 0.2277
- 2028: 0.2277
- hadap: 0.2277
- lahir: 0.2172
- harap: 0.2172
- sukses: 0.2005

--- Group: BeritaKaltim.Co ---
- dorong: 0.4258
- co: 0.3893
- balikpapan: 0.2826
- genjot: 0.2826
- destinasi: 0.2826
- geliat: 0.2643
- perintah: 0.2502
- perhati: 0.2502
- wali: 0.2386
- tourism: 0.2289

```

4.3.3.3 Hasil TF-IDF per Bulan (*Time Frame*)

Analisis temporal TF-IDF mengelompokkan artikel berdasarkan bulan rilisnya untuk melihat perkembangan topik dari waktu ke waktu. Dilakukan pengestrakan *date&time* dari masing-masing artikel dan *filtering* artikel yang memiliki bulan yang valid.

Gambar 4.18 Hasil Artikel Valid per Informasi Rilis Bulan-Tahun

```

Total articles with valid month: 65
Unique months: 13
Articles per month:
month
2025-05      9
2025-06     17
2025-07     39
2025-08     47
2025-09     28
2025-10     38
2025-11     84
2025-12     59
2026-01     38
2026-02    149
2026-03     66
2026-04     63
2026-05     14

```

Setelah itu, dicari 10 kata paling signifikan di setiap bulannya. Hasil ini memberikan gambaran mengenai pergeseran fokus pemberitaan dan kemunculan isu-isu baru pada periode tertentu. Gambar 4.19 menampilkan kata-kata yang paling signifikan untuk setiap periode bulan yang tersedia dalam dataset.

Gambar 4.19 Top 10 TF-IDF per Bulan

```

=== Top 10 TF-IDF Words per Month ===

--- Group: 2025-05 ---
- sirkuit: 0.4720
- rekomendasi: 0.2886
- detiksport: 0.2418
- 2025: 0.2235
- open: 0.2072
- harpersbazaar: 0.1969
- jaring: 0.1969
- coba: 0.1746
- 2028: 0.1746
- pon: 0.1746

--- Group: 2025-06 ---
- fasilitas: 0.2619
- putri: 0.2489
- bal: 0.2488
- olahraga: 0.2261
- 2025: 0.2119
- kenal: 0.1988
- juara: 0.1824
- internasional: 0.1824
- harga: 0.1696
- bangun: 0.1413

--- Group: 2025-07 ---
- kena: 0.2673
- olahraga: 0.2428
- tripzilla: 0.2370
- surabaya: 0.2285
- 10: 0.2227
- 2025: 0.1896
- sewa: 0.1758
- juta: 0.1632
- rekomendasi: 0.1632
- bca: 0.1601

--- Group: 2025-08 ---
- kumpar: 0.3337
- olahraga: 0.2346
- jambi: 0.2295
- rekomendasi: 0.1682
- target: 0.1669
- bola: 0.1669
- 10: 0.1529
- kalong: 0.1526
- tren: 0.1409
- kualitas: 0.1375

--- Group: 2025-09 ---
- sirnas: 0.2982
- kapanlagi: 0.2236
- harga: 0.1910
- gresik: 0.1681
- soccer: 0.1681
- pasar: 0.1681
- surabaya: 0.1643
- disway: 0.1548
- final: 0.1491
- bangun: 0.1431

--- Group: 2025-10 ---
- 2025: 0.3173
- ambruk: 0.2096
- final: 0.1859
- timnas: 0.1859
- detiksport: 0.1716
- rekomendasi: 0.1707
- olahraga: 0.1587
- makassar: 0.1524
- sewa: 0.1470
- zar: 0.1397

--- Group: 2025-11 ---
- rekomendasi: 0.4088
- harga: 0.2693
- 2025: 0.2375
- juta: 0.2044
- rp1: 0.1855
- murah: 0.1671
- ribu: 0.1546
- mula: 0.1533
- kumpar: 0.1521
- hadir: 0.1426

--- Group: 2025-12 ---
- 2025: 0.2188
- mula: 0.2119
- rekomendasi: 0.2119
- sinar: 0.1927
- harga: 0.1532
- kompetisi: 0.1479
- liputan6: 0.1479
- outdoor: 0.1445
- beyond: 0.1445
- mas: 0.1445

--- Group: 2026-01 ---
- merdeka: 0.2940
- semarang: 0.2450
- olahraga: 0.1837
- iims: 0.1793
- kalong: 0.1793
- 2026: 0.1772
- rekomendasi: 0.1646
- buka: 0.1646
- jateng: 0.1470
- konser: 0.1348

--- Group: 2026-02 ---
- warga: 0.4721
- bising: 0.3128
- pramono: 0.2620
- protes: 0.2086
- pemprov: 0.1695
- viral: 0.1695
- bangun: 0.1677
- putih: 0.1564
- kumpar: 0.1517
- nawi: 0.1390

--- Group: 2026-03 ---
- segel: 0.6126
- izin: 0.3067
- pemkot: 0.1838
- beritajakarta: 0.1360
- siap: 0.1225
- metrotvnews: 0.1177
- porprov: 0.1150
- cilandak: 0.1150
- slf: 0.1150
- pbg: 0.1150

--- Group: 2026-04 ---
- sirnas: 0.3347
- semarang: 0.2994
- 2026: 0.2347
- 800: 0.2130
- ledak: 0.1716
- olahraga: 0.1559
- seri: 0.1521
- ii: 0.1521
- tourism: 0.1521
- gratis: 0.1521

```

4.3.3.4 Hasil TF-IDF per Kata Kunci Pencarian

Analisis TF-IDF berdasarkan kata kunci pencarian yang digunakan saat scraping bertujuan untuk memvalidasi relevansi artikel dan mengidentifikasi kata-kata yang paling khas untuk setiap topik pencarian. Gambar 4.20 menampilkan hasil analisis ini untuk setiap kata kunci yang memiliki minimal dua artikel dalam corpus.

Gambar 4.20 Top 10 TF-IDF per *Keywords* Pencarian

```
Total articles with valid keywords (at least 2 per keyword): 789
Unique keywords analyzed: 39

=== Top 10 TF-IDF Words per Keyword ===

--- Group: World Padel Tour Indonesia ---
- cirebon: 0.4047
- young: 0.3722
- on: 0.3265
- kombinasi: 0.3265
- gengsi: 0.3092
- viral: 0.2484
- top: 0.2394
- squash: 0.2394
- usia: 0.2160
- tenis: 0.1908

--- Group: atlet padel Indonesia ---
- atlet: 0.5116
- games: 0.2165
- asi: 0.1896
- pbpi: 0.1829
- galih: 0.1804
- nasional: 0.1701
- indonesia: 0.1649
- olimpiade: 0.1517
- cabor: 0.1402
- cup: 0.1263

--- Group: bisnis padel ---
- hijab: 0.3657
- bahan: 0.3529
- keringat: 0.2387
- inner: 0.1988
- antik: 0.1988
- olahraga: 0.1883
- aditya: 0.1705
- rezky: 0.1705
- pilih: 0.1647
- bisnis: 0.1644

--- Group: federasi padel ---
- net: 0.4734
- meter: 0.4119
- tiang: 0.2817
- ukur: 0.2621
- fip: 0.2152
- dinding: 0.1818
- atur: 0.1693
- panel: 0.1690
- jaring: 0.1333
- federasi: 0.1291

--- Group: harga padel ---
- ribu: 0.4354
- murah: 0.2903
- rekomendasi: 0.2825
- kader: 0.1997
- kece: 0.1997
- sulsel: 0.1837
- rp100: 0.1837
- de: 0.1713
- rp300: 0.1713
- diskon: 0.1713

--- Group: investasi padel ---
- singgung: 0.2225
- id: 0.2161
- pemkot: 0.2130
- segel: 0.2049
- dprd: 0.1795
- bisnis: 0.1725
- kontan: 0.1700
- bangun: 0.1681
- polemik: 0.1617
- co: 0.1596

--- Group: klub padel ---
- klub: 0.2805
- gino: 0.2616
- galih: 0.2376
- pb: 0.2376
- pi: 0.1901
- jakarta: 0.1694
- atlet: 0.1498
- club: 0.1362
- pabrik: 0.1308
- kilat: 0.1308

--- Group: kompetisi padel ---
- kompetisi: 0.3661
- fomo: 0.2763
- gak: 0.2277
- olahraga: 0.1886
- merdeka: 0.1842
- seru: 0.1771
- iims: 0.1607
- main: 0.1505
- konser: 0.1327
- turnamen: 0.1322

-- Group: komunitas padel ---
- lari: 0.3156
- tingkat: 0.3010
- komunitas: 0.2372
- olahraga: 0.1897
- data: 0.1434
- main: 0.1419
- langkah: 0.1286
- catat: 0.1203
- tumbuh: 0.1203
- indonesia: 0.1181

-- Group: lapangan padel ---
- segel: 0.4656
- bangun: 0.2413
- jakarta: 0.2068
- metrotvnews: 0.1783
- iin: 0.1597
- kumpar: 0.1592
- pramono: 0.1491
- warga: 0.1400
- permanen: 0.1385
- dki: 0.1358

-- Group: lapangan padel Jakarta ---
- segel: 0.3910
- bangun: 0.3562
- dokumen: 0.2803
- izin: 0.2182
- jakarta: 0.1815
- iin: 0.1784
- tindak: 0.1667
- pasang: 0.1532
- spanduk: 0.1530
- cktrp: 0.1530

-- Group: olahraga padel ---
- segel: 0.2952
- bangun: 0.2544
- jakarta: 0.2414
- izin: 0.1922
- olahraga: 0.1898
- main: 0.1636
- wilayah: 0.1585
- tindak: 0.1573
- lokasi: 0.1417
- awas: 0.1286
```

4.3.3.5 Hasil *POS Tagging*

POS Tagging dilakukan menggunakan pustaka Stanza dengan model pra-terlatih bahasa Indonesia. Setiap token dalam kolom *after_lemmatization* diberi label jenis kata sesuai *Universal Dependencies tagset*, yang mencakup antara lain NOUN (kata benda), VERB (kata kerja), ADJ (kata sifat), ADV (kata keterangan), PROP (nama diri), dan NUM (angka).

Hasil POS tagging memungkinkan analisis struktur gramatikal corpus secara kuantitatif. Gambar 4.21 menampilkan contoh hasil anotasi POS tagging pada beberapa artikel berita.

Gambar 4.21 Hasil POS Tagging pada Corpus Berita

	judul	after_lemmatization	pos_tags
0	Riset: Laju Properti 2026 Moderat, Lapangan Pa...	riset laju properti 2026 moderat lapang padel ...	[NOUN, NOUN, NOUN, NUM, ADJ, NOUN, NOUN, NOUN, ...
1	Berapa Biaya Bangun Lapangan Padel? Ini Rincia...	biaya bangun lapang padel rinciannya bloomberg...	[NOUN, VERB, NOUN, NOUN, NOUN, PRON, PROPN, PR...
2	Maple Padel, Lapangan Padel Rooftop Pertama di...	maple padel lapang padel rooftop jateng rri co id	[NOUN, NOUN, NOUN, NOUN, NOUN, NOUN, NOUN, NOU...
3	Pramono Resmi Larang Pembangunan Lapangan Pade...	pramono resmi larang bangun lapang padel zona ...	[PROPN, ADJ, VERB, VERB, NOUN, NOUN, NOUN, NOU...
4	Baru Pertama Main Padel? Ini Cara Bermain yang...	padel olahraga viral gari indonesia cinta olah...	[NOUN, NOUN, NOUN, NOUN, PROPN, NOUN, NOUN, NO...

4.3.3.6 Hasil Named Entity Recognition (NER)

Named Entity Recognition dilakukan menggunakan pipeline Stanza yang sama dengan POS tagging, sehingga proses tokenisasi dan segmentasi kalimat dilakukan secara konsisten. NER mengidentifikasi dan mengklasifikasikan entitas bernama dalam teks ke dalam kategori seperti PER (nama orang), ORG (organisasi), LOC (lokasi), dan lainnya.

Gambar 4.22 menampilkan contoh hasil identifikasi entitas pada beberapa artikel berita beserta kategorinya.

Gambar 4.22 Hasil Named Entity Recognition (NER)

	judul	ner_entities_transformers
0	Riset: Laju Properti 2026 Moderat, Lapangan Pa...	[(2026, CRD), (lapangan padel, LOC), (cnn indo...
1	Berapa Biaya Bangun Lapangan Padel? Ini Rincia...	[(lapangan padel, LOC), (bloomberg technoz, ORG)]
2	Maple Padel, Lapangan Padel Rooftop Pertama di...	[(maple padel, LOC), (lapangan padel rooftop, ...
3	Pramono Resmi Larang Pembangunan Lapangan Pade...	[(pramono, PER), (lapangan padel, LOC), (cnn i...
4	Baru Pertama Main Padel? Ini Cara Bermain yang...	[(pertama, ORD)]

4.3.3.7 Hasil Analisis N-gram (Bigram)

Analisis bigram (pasangan kata berurutan) menggunakan pendekatan TF-IDF yang sama dengan analisis unigram, namun dengan parameter ngram_range=(2,2). Analisis ini mengidentifikasi frasa-frasa yang bermakna dan sering muncul bersama dalam corpus, yang tidak dapat dideteksi dari kata tunggal saja.

Analisis bigram dilakukan per dimensi waktu (per bulan) untuk melacak bagaimana frasa-frasa penting berevolusi seiring perkembangan pemberitaan. Gambar 4.23 menampilkan top bigram per bulan yang tersedia dalam dataset.

Gambar 4.23 Top Bigram per Bulan

	month	rank	term	tfidf
0	2025-05	1	indonesia open	0.3462
1	2025-05	2	sirkuit indonesia	0.3462
2	2025-05	3	rekomendasi raket	0.2125
3	2025-05	4	2025 hadir	0.1731
4	2025-05	5	kualitas harga	0.1731
...	...	...	...	...
125	2026-05	6	20detik pbpi	0.1887
126	2026-05	7	siap atlet	0.1887
127	2026-05	8	beritajateng id	0.1887
128	2026-05	9	grand opening	0.1887
129	2026-05	10	viva co	0.1887

BAB V

PENUTUP

5.1 Kesimpulan

Penelitian ini berhasil menunjukkan bahwa model IndoBERT yang di-*fine-tune* mampu diterapkan untuk tugas analisis sentimen pada domain artikel berita daring berbahasa Indonesia mengenai olahraga padel. Model mencapai akurasi keseluruhan sebesar 87%, yang mengindikasikan bahwa pendekatan *fine-tuning* berbasis IndoBERT relevan dan layak untuk diimplementasikan pada domain berita olahraga spesifik yang belum pernah dieksplorasi sebelumnya. Temuan ini selaras dengan penelitian-penelitian terdahulu yang juga mencatatkan keunggulan model berbasis *Transformer* dibandingkan pendekatan *machine learning* klasik pada teks berbahasa Indonesia.

Meskipun demikian, tingginya akurasi keseluruhan tersebut sangat dipengaruhi oleh dominasi kelas netral dalam dataset. Ketidakeimbangan distribusi data yang sangat tinggi, dengan 711 artikel netral, 70 artikel positif, dan hanya 8 artikel negatif, menyebabkan model cenderung mengklasifikasikan hampir seluruh data sebagai netral. Hal ini tercermin dari rendahnya performa model pada kelas minoritas, di mana *precision* kelas positif hanya mencapai 0,15 dan *recall* sebesar 0,03, sedangkan kelas negatif memperoleh *precision* sebesar 0,05 dan *recall* sebesar 0,12. Nilai *macro average F1-score* sebesar 0,35 menegaskan bahwa ketidakeimbangan kelas merupakan tantangan utama yang harus diatasi pada penelitian selanjutnya.

Dari sisi variasi panjang input teks, penggunaan *max sequence length* sebesar 256 token dengan parameter *truncation=True* memungkinkan model memproses artikel berita dengan efisien. Namun, mengingat artikel berita daring cenderung memiliki panjang teks yang lebih kompleks dibandingkan data media sosial, sebagian konteks informasi berpotensi terpotong selama proses tokenisasi. Hal ini menjadi faktor yang turut berkontribusi terhadap rendahnya kemampuan model dalam menangkap nuansa sentimen implisit yang sering kali tersebar di berbagai bagian artikel.

Analisis distribusi sentimen mengungkap bahwa sebagian besar pemberitaan padel di Indonesia bersifat netral (95,7%), yang mengindikasikan bahwa pemberitaan padel di media daring nasional masih didominasi oleh konten informatif dan faktual, seperti liputan turnamen, profil pemain, dan perkembangan fasilitas, alih-alih konten opini atau evaluatif yang kuat. Sementara itu, analisis TF-IDF yang dilakukan per kelas sentimen berhasil mengungkap pola tematik yang berbeda antar kelas: artikel bersentimen positif banyak memuat kata-kata terkait ‘turnamen’, ‘olahraga’, ‘gratis’, dan ‘sehat’; artikel bersentimen netral didominasi oleh kata teknis seperti ‘raket’, ‘lapangan’, dan ‘rekomendasi’; sedangkan artikel bersentimen negatif

banyak menyinggung ‘keluhan warga’, ‘pemukiman’, dan ‘batas’, yang mengindikasikan adanya isu konflik sosial terkait pembangunan fasilitas padel di kawasan perumahan.

Analisis fitur tambahan berupa *POS tagging*, *Named Entity Recognition* (NER), dan analisis N-gram memberikan pemahaman yang lebih mendalam mengenai struktur linguistik korpus berita padel. Hasil NER menggunakan pustaka Stanza berhasil mengidentifikasi entitas-entitas penting seperti nama atlet, lokasi turnamen, dan organisasi olahraga yang dominan dalam pemberitaan, sementara analisis bigram per bulan memperlihatkan evolusi frasa-frasa kunci yang mencerminkan dinamika dan pergeseran topik pemberitaan olahraga padel dari waktu ke waktu. Temuan-temuan dari analisis fitur ini dapat menjadi dasar yang kuat bagi pemangku kepentingan, seperti pengelola klub, investor, dan asosiasi olahraga, dalam memahami tren opini publik terhadap padel secara lebih terukur dan berbasis data.

5.2 Saran

Berdasarkan temuan dan keterbatasan yang diperoleh dalam penelitian ini, penanganan ketidakseimbangan kelas perlu menjadi prioritas utama pada penelitian berikutnya. Strategi yang dapat diterapkan meliputi teknik *oversampling* seperti SMOTE (*Synthetic Minority Oversampling Technique*) pada level representasi teks, penggunaan bobot kelas (*class weighting*) dalam fungsi *loss* selama proses *fine-tuning*, serta penerapan teknik augmentasi data teks pada kelas minoritas untuk memperbanyak sampel sentimen positif dan negatif. Selain itu, perluasan dataset secara kuantitatif melalui pengumpulan artikel dalam rentang waktu yang lebih panjang dan cakupan portal berita yang lebih beragam juga sangat direkomendasikan, dengan fokus pada upaya aktif mengumpulkan lebih banyak artikel yang berpotensi mengandung sentimen non-netral.

Eksplorasi konfigurasi *hyperparameter* yang lebih sistematis juga perlu dilakukan pada penelitian selanjutnya, khususnya terkait variasi *max sequence length*, *learning rate*, jumlah *epoch*, dan strategi *learning rate scheduler*. Mengingat artikel berita cenderung memiliki struktur teks yang lebih panjang dan formal dibandingkan data media sosial, pengujian dengan nilai *max sequence length* yang lebih besar, misalnya hingga 512 token, berpotensi meningkatkan kemampuan model dalam menangkap konteks penuh dan nuansa sentimen yang tersebar di seluruh bagian artikel.

Pendekatan *Aspect-Based Sentiment Analysis* (ABSA) dapat dieksplorasi sebagai pengembangan lanjutan dari penelitian ini. Alih-alih hanya mengklasifikasikan sentimen secara keseluruhan per artikel, ABSA memungkinkan identifikasi sentimen pada aspek-aspek spesifik dalam berita padel, seperti aspek fasilitas lapangan, biaya, penyelenggaraan turnamen, atau komunitas pemain, sehingga menghasilkan wawasan yang lebih granular dan dapat langsung dimanfaatkan oleh para pemangku kepentingan. Di samping itu, perbandingan dengan model bahasa yang lebih mutakhir, seperti IndoBERT-large atau arsitektur *ensemble* yang menggabungkan beberapa model, juga dapat dilakukan untuk mengidentifikasi konfigurasi yang paling optimal dan meningkatkan *robustness* klasifikasi sentimen, khususnya pada kelas-kelas minoritas yang masih menjadi kelemahan utama dalam penelitian ini.

DAFTAR PUSTAKA

- Adrian, M., et al. (2025). Analisis sentimen tim nasional Indonesia pada AFF 2024 menggunakan Naive Bayes dan KNN. *Jurnal Ilmu Komputer*.
- Antara News. (2025). *Menpora Dito dukung perkembangan olahraga padel di Indonesia*. <https://www.antaraneews.com/berita/4849029/menpora-dito-dukung-perkembangan-olahraga-padel-di-indonesia>
- Das, S., & Chakraborty, S. (2019). An approach to sentiment analysis on social media using TF-IDF and machine learning techniques. *International Journal of Computer Applications*, 182(26), 14–18.
- Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 1, 4171–4186.
- Gunawan, W., et al. (2018). Named entity recognition for Indonesian language using natural language processing. *Journal of Physics: Conference Series*.
- IEEE ICCCNT. (2023). Systematic review of NLP methods for news sentiment classification. *Proceedings of the International Conference on Computing, Communication and Networking Technologies*.
- Junaidi, A., et al. (2025). Fine tuning model IndoBERT untuk analisis sentimen berita pariwisata Indonesia. *Jurnal Pendidikan Teknologi dan Kejuruan, Undiksha*, 22(1), 77.
- Kaswidjanti, W., et al. (2022). Sentiment analysis of Indonesian reviews using fine-tuning IndoBERT and R-CNN. *ILKOM Jurnal Ilmiah*, 14(3).
- Katadata. (2025). *Jumlah klub dan lapangan padel di Indonesia tumbuh pesat sampai 2025*. <https://databoks.katadata.co.id/olahraga/statistik/699fd44e1c1db/jumlah-klub-dan-lapangan-padel-di-indonesia-tumbuh-pesat-sampai-2025>
- Khairunnisa, S., et al. (2020). Part-of-speech tagging for Indonesian language using deep learning. *International Journal of Advanced Computer Science and Applications*.
- Kompas.com. (2025, July 2). *Indonesia mendadak padel?*. <https://www.kompas.com/jawa-timur/read/2025/07/02/181500288/indonesia-mendadak-padel>

Liputan6.com. (2025). *Sejarah dan perkembangan olahraga padel di Indonesia: Dibawa ekspatriat hingga jadi tren urban*.
<https://www.liputan6.com/bola/read/6151270/sejarah-dan-perkembangan-olahraga-padel-di-indonesia-dibawa-ekspatriat-hingga-jadi-tren-urban>

Patel, A., Oza, P., & Agrawal, S. (2022). Sentiment analysis of customer feedback and reviews for airline services using language representation model. *Procedia Computer Science*, 218, 2459–2467. <https://doi.org/10.1016/j.procs.2023.01.221>

Perwira, I. G. B. S., et al. (2025). Domain-specific fine-tuning of IndoBERT for aspect-based sentiment analysis in Indonesian travel user-generated content. *Journal of Information Systems Engineering and Business Intelligence (JISEBI)*.

Prasetyo, B., et al. (2024). A comparative analysis of MultinomialNB, SVM, dan BERT pada sentimen Twitter Garuda Indonesia. *PIKSEL Journal*, 12(1), 75.

Rifaldy, M., et al. (2025). Comparative study of TF-IDF and word embeddings in sports sentiment analysis. *Indonesian Journal of Data Science*.

Rozado, D., Hughes, R., & Halberstadt, J. (2022). Longitudinal analysis of sentiment and emotion in news media headlines using transformer language models. *PLOS ONE*, 17(10), e0276367.

Singh, N., et al. (2022). Sentiment analysis on sports facilities using machine learning. *International Journal of Information Management*.

Talaat, A. S. (2023). Sentiment analysis classification system using hybrid BERT models. *Journal of Big Data*, 10(1).

Wibawa, A. P., et al. (2016). Part-of-speech tagging for Indonesian language: A review. *Journal of Engineering and Applied Sciences*.

Wilie, B., et al. (2020). IndoNLU: Benchmark and resources for evaluating Indonesian natural language understanding. *Proceedings of the 1st Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics and the 10th International Joint Conference on Natural Language Processing (ACL-IJCNLP)*.

LAMPIRAN